

PI2T Développement informatique

Séance 5

Programmation concurrente



Objectifs

- Calcul parallèle et distribué
 - Système d'exploitation
 - Processus et threads
 - Multiprocesseur
- Librairie Python de calcul distribué et parallèle
 - Multiprocessing
 - Threading
 - Calcul distribué avec dispy



IBM 704

■ Exécution séquentielle des programmes l'un après l'autre



Système d'exploitation

- Couche logicielle intermédiaire entre l'utilisateur et le hardware
 Le seul programme qui tourne toujours sur une machine allumée
- Abstraction des installations matérielles sous-jacentes
 Permet aux programmes de communiquer avec le hardware
- Gestion de plusieurs aspects liés à l'environnement Processus, fichier, mémoire, socket, dessin à l'écran...

Multiprogrammation

Système d'exploitation

Programme utilisateur

Système d'exploitation

Job 1

Job 2

Job 3

Système simple par lot

Traitement par lot multiprogrammé

Processus (1)

- Un processus est un programme en cours d'exécution
 Plusieurs processus peuvent exister pour un même programme
- Plusieurs caractéristiques liés aux processus
 - Processus gérés par le système d'exploitation
 - Trois flux connectés : entrée/sortie standard
 - Code de retour après exécution (0 terminaison normale)
- Informations sur le processus avec le module sys

Processus (2)

- Flux accessibles avec sys.stdout, sys.stderr et sys.stdin

 Mêmes méthodes que pour manipuler des fichiers
- Forcer l'écriture des sorties avec flush

Le système d'exploitation stocke temporairement dans des buffers

```
import sys

print('Année de naissance ? ', end='')

sys.stdout.flush()
data = sys.stdin.read()
print('Vous avez', 2016 - int(data), 'ans.')
sys.exit(0)
```

Note : il faut utiliser CTRL+D pour envoyer l'entrée standard

Calcul parallèle et distribué

- Exécution concurrente de plusieurs activités
 Rendue possible avec la multiprogrammation
- Exécution parallèle de plusieurs activités
 Rendue possible avec les multi-processeurs
- Plusieurs sources de parallélisme (os.cpu_count())
 - Processeurs multicœurs, multithreadé, co-processeurs
 - Plusieurs processeurs
 - Plusieurs machines reliées par le réseau (cluster)

Concurrence \neq Parallélisme

Taxonomie de Flynn

- SISD (single-instruction, single-data)

 Ordinateur séquentiel sans aucun parallélisme (von Neumann)
- SIMD (single-instruction, multiple-data)
 Parallélisme de mémoire, même opération sur plusieurs données (processeur vectoriel)
- MIMD (multiple-instruction, multiple-data)
 Plusieurs unités de calcul traitent des données différentes

Application multi-processus

- Exécution de plusieurs processus indépendants
 Chaque processus possède ses propres ressources
- Communication et partage de données pas évident
 - Fournir les données au lancement du nouveau processus
 - Communication par le réseau
 - Utilisation de services spécifiques au système d'exploitation

Module subprocess

- Exécution de processus et récupération d'informations

 Connexion aux entrées/sorties et récupération code de retour
- Exécution d'un processus avec la fonction run
 Prends la liste des arguments de l'appel en paramètre

```
import subprocess

p = subprocess.run(['pwd'])
print('Valeur de retour :', p.returncode)
```

```
/Users/combefis/Desktop
Valeur de retour : 0
```

Redirection des flux

- Possibilité de rediriger les entrées et sorties (std et err)
- Plusieurs redirections possibles
 - Dans le néant avec subprocess.DEVNULL
 - Vers un fichier avec un descripteur
 - Vers un nouveau pipe créé avec subprocess.PIPE

```
import subprocess

with open('result.txt', 'w') as file:
    p = subprocess.run(['pwd'], stdout=file, stderr=subprocess.
    DEVNULL)
    print('Valeur de retour :', p.returncode)
```

```
Valeur de retour : 0
```

Objet Popen

- Processus représenté par un objet Popen
 Beaucoup plus flexible que de passer par la fonction run
- Constructeur de la classe similaire à la fonction run

 Liste des arguments, puis autres options

```
import subprocess

proc = subprocess.Popen(['pwd'])
proc.wait()
print('Fini avec code de retour :', proc.returncode)
```

Communication avec un processus

- Méthode communicate pour envoyer données sur stdin
 - Communication en str grâce à universal_newlines=True
 - Redirection des flux vers subprocess.PIPE

```
import subprocess

proc = subprocess.Popen(['python3'], stdin=subprocess.PIPE, stdout=
    subprocess.PIPE, universal_newlines=True)

out, err = proc.communicate('print(1 + 2)\nimport os\nprint(os.
    getcwd())\nexit()')
print(out)
```

```
3
/Users/combefis/Desktop
```

Module multiprocessing

3

5

- Parallélisme par exploitation des multi-processeurs
 Permet de lancer plusieurs processus localement ou à distance
- Parallélisme de données à l'aide d'objets Pool
 Exécution d'une même fonction sur plusieurs données

```
import multiprocessing as mp
def compute(data):
    return data ** 2
with mp.Pool(3) as pool:
    print(pool.map(compute, [1, 7, 8, -2]))
```

```
[1, 49, 64, 4]
```

Lancer un processus

Processus représenté par un objet Process
 Code du processus défini par une fonction passée au constructeur

Méthode start pour lancer le processus

```
import multiprocessing as mp

def sayhello(name):
    print('Hello', name)

proc = mp.Process(target=sayhello, args=('Dan',))
proc.start()

proc.join() # Attendre la fin du processus
print('Terminé avec code', proc.exitcode)
```

```
Hello Dan
Terminé avec code 0
```

Communication interprocessus

- Possibilité d'échanger des objets entre processus
 Permet une communication bidirectionnelle entre deux processus
- Deux constructions différentes proposées
 - File de communication (Queue)
 - **Tube** de communication (Pipe)
- Attendre la fin d'un processus avec la méthode join Méthode join bloquante

Communication par Queue

Création de la Queue et passation au processus fils

Méthodes put et get pour écrire et lire dans la file

```
import multiprocessing as mp

def compute(q):
    q.put('Hey!')

q = mp.Queue()
proc = mp.Process(target=compute, args=(q,))
proc.start()
print(q.get())

proc.join()
print('Terminé avec code', proc.exitcode)
```

```
Hey!
Terminé avec code 0
```

Communication par Pipe

Création du Pipe et passation d'un bout au processus fils

Méthodes send et recu pour envoyer et recevoir des données

```
import multiprocessing as mp
3
    def compute(child):
        child.send('Hey!')
        child.close()
6
7
    parent, child = mp.Pipe()
   proc = mp.Process(target=compute, args=(child,))
   proc.start()
   print(parent.recv())
10
11
12
    proc.join()
    print('Terminé avec code', proc.exitcode)
13
```

```
Hey!
Terminé avec code 0
```

Pool de workers

■ Création d'un Pool de processus

Nombre de processus dans le pool à spécifier au constructeur

- Plusieurs méthodes pour lancer une exécution
 - apply fait exécuter une fonction par un worker
 - map fait exécuter une fonction avec plusieurs données
 - starmap lorsque plusieurs paramètres pour la fonction

```
import multiprocessing as mp

def compute(a, b):
    return a + b

with mp.Pool(3) as pool:
    print(pool.starmap(compute, [(1, 2), (7, -4), (9, 3)]))
```

Mode d'exécution synchrone

8

9 10

11

12

Mode d'exécution synchrone par défaut

Le processus parent attend la fin de l'exécution de son fils

```
import multiprocessing as mp
import random
import time

def temperature(city):
    print('Lancé', city)
    time.sleep(random.randint(0, 3))
    return random.randint(0, 25)

with mp.Pool(3) as pool:
    for city in ['Belgium', 'Croatia', 'Poland']:
        print('>', city, pool.apply(temperature, (city,)))
```

```
Lancé Belgium
> Belgium 20
Lancé Croatia
> Croatia 21
Lancé Poland
> Poland 3
```

Mode d'exécution asynchrone (1)

- Version asynchrone des méthode de Pool
 Appel pas bloquant renvoie un objet de type AsyncResult
- Lance le processus et se termine directement
 Attente de la réponse avec méthode get de AsyncResult

Mode d'exécution asynchrone (2)

5

8

9 10

11

12

13

14

15

16 17

18

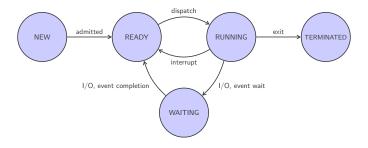
```
import multiprocessing as mp
import random
import time
def temperature(citv):
    print('Lancé', city)
    time.sleep(random.randint(0, 3))
    return random.randint(0, 25)
with mp.Pool(3) as pool:
    results = []
    for city in ['Belgium', 'Croatia', 'Poland']:
        results.append((city, pool.apply_async(temperature, (city,))))
    i = 0
    while i < len(results):
        city, result = results[i]
        print('>', city, result.get())
        i += 1
```

```
Lancé Belgium
Lancé Croatia
Lancé Poland
> Belgium 21
> Croatia 23
> Poland 1
```



Thread

- Processus léger à l'intérieur d'un processus
 Plusieurs états lors de l'exécution d'un thread
- Un thread terminé ne peut pas être redémarré



Application multi-threads

- Exécution de plusieurs threads d'exécution indépendants
 Partage des ressources avec le processus hôte
- Gestion des threads possible par le système d'exploitation
 Ou gestion directe par le processus
- Gestion de la concurrence pas évident
 - Synchronisation et plusieurs threads
 - Évitement des interblocages (deadlocks)

Attendre un certain temps

- Blocage du programme avec fonction sleep du module time Blocage uniquement du thread qui a exécuté l'appel
- Spécification du temps de blocage en secondes (flottant)

```
import sys
import time

print('Bonjour', end='')
sys.stdout.flush()
time.sleep(1.5)
print(' toi.')
```

```
Bonjour toi.
```

Planifier une action

- Planification d'une exécution à l'aide d'un objet Timer
 Choix de la fonction à exécuter et du temps d'attente
- Création d'un objet Timer puis appel à la méthode start

```
import threading as th

def sayhello(name):
    print('Hello', name)

t = th.Timer(5.5, sayhello, args=('Bob',))

t.start()
print('Timer started')
```

```
Timer started
Hello Bob
```

Répéter une action

■ Répétition d'actions avec le module sched

Ajout d'action à planifier avec la méthode enter

Création d'un objet scheduler puis appel à la méthode run

```
import sched
    from datetime import datetime
    import sys
    import time
5
6
    def printhour():
        print('\r{0:%H:%M:%S}'.format(datetime.now()), end='')
        svs.stdout.flush()
9
        scheduler.enter(1, 1, printhour)
10
11
    scheduler = sched.scheduler(time.time, time.sleep)
12
    scheduler.enter(1, 1, printhour)
    scheduler.run()
13
```

Module threading

Parallélisme par création de processus légers

Création plus rapide par rapport à un processus

Un thread possède un nom

3

5

Accessible par l'attribut name

```
import concurrent.futures as cf

def compute(data):
    return data ** 2

with cf.ThreadPoolExecutor(3) as executor:
    print(list(executor.map(compute, [1, 7, 8, -2])))
```

```
[1, 49, 64, 4]
```

Lancer un thread

- Thread représenté par un objet Thread
 Code du thread défini par une fonction passée au constructeur
- Méthode start pour lancer le thread

```
import threading as th

def sayhello(name):
    print('Hello', name)

thread = th.Thread(target=sayhello, args=('Tom',))
thread.start()

thread.join() # Attendre la fin du thread
print('Thread', thread.name, 'terminé')
```

```
Hello Tom
Thread Thread-1 terminé
```

Protection des données partagées (1)

- Les threads partagent les données du processus
 Attention aux modifications concurrentes des données partagées
- Utilisation d'un lock pour protéger l'accès
 Un seul thread à la fois accède à la donnée partagée
- Lock représenté par objet Lock
 Méthode acquire pour obtention et release pour libération

Protection des données partagées (2)

```
from random import randint
   import threading as th
    from time import sleep
   counter = 0
   results = {}
8
   def compute(name):
        global counter
        counter += 1
10
        sleep(randint(0, 1))
11
        results[name] = counter
12
13
14
   threads = [th.Thread(target=compute, args=(name,)) for name in ['
    Dan', 'Tom']]
15
   for thread in threads:
        thread.start()
16
   for thread in threads:
17
18
        thread.join()
19
    print(results)
```

```
{'Tom': 2, 'Dan': 2}
```

Protection des données partagées (3)

```
# ...
2
    counter = 0
    results = {}
    lock = th.Lock()
7
    def compute(name):
        global counter
        lock.acquire()
10
        counter += 1
11
        sleep(randint(0, 1))
12
        results[name] = counter
13
        lock.release()
14
15
```

```
# ...
    counter = 0
    results = {}
    lock = th.Lock()
    def compute(name):
        global counter
        with lock:
10
            counter += 1
            sleep(randint(0, 1))
11
12
            results[name] = counter
13
14
15
```

```
{'Tom': 2, 'Dan': 1}
```

Pool d'executor

■ Création d'un Pool de threads

Nombre de threads dans le pool à spécifier au constructeur

- Plusieurs méthodes pour lancer une exécution
 - submit fait exécuter une fonction par un executor
 - map fait exécuter une fonction avec plusieurs données

```
import concurrent.futures as cf

def compute(data):
    a, b = data
    return a + b

with cf.ThreadPoolExecutor(3) as executor:
    print(list(executor.map(compute, [(1, 2), (7, -4), (9, 3)])))
```



Framework dispy

- Création et utilisation de clusters pour du calcul parallèle
 - Plusieurs processeurs sur la même machine (SMP)
 - À travers plusieurs machines dans un cluster
- Adapté pour le parallélisme de données (SIMD)
 Le même programme est exécuté avec des données différentes
- Gestion dynamique des nodes du cluster
 L'ordonnanceur de dispy répartit les jobs

Composants

dispy (client)
Création d'un cluster (JobCluster ou SharedJobCluster)

dispynode (serveur)
 Exécution de jobs reçus d'un client, tourne sur chaque node

dispyscheduler (exécution partagée)
Ordonnance les jobs lorsque en mode SharedJobCluster

dispynetrelay (serveurs à distance)
 Réparti les jobs lorsque les nodes sont sur différents réseaux

Démarrage d'un node

■ Démarrage du programme dispynode.py sur chaque node

Possibilité d'interroger le serveur pour avoir des stats

```
$ dispynode.py
2016-03-06 10:26:22,305 - dispynode - dispynode version 4.6.9
2016-03-06 10:26:22,780 - dispynode - serving 4 cpus at
192.168.1.4:51348
Enter "quit" or "exit" to terminate dispynode,
  "stop" to stop service, "start" to restart service,
  "cpus" to change CPUs used, anything else to get status: BLABLA
  Serving 4 CPUs
  Completed:
    O Computations, O jobs, 0.000 sec CPU time
  Running:
Enter "quit" or "exit" to terminate dispynode,
  "stop" to stop service, "start" to restart service,
  "cpus" to change CPUs used, anything else to get status:
```

Exécution d'un job (1)

■ Définition d'un job par une fonction

Rien de particulier à faire, fonction tout à fait classique

```
import dispy
import random
import time

def compute(n):
    result = n ** 2
    time.sleep(random.randint(1, 5))
    return (n, result)

# ...
```

Exécution d'un job (2)

- Création d'un nouveau cluster de type JobCluster Envoi des jobs sur le cluster avec la méthode submit
- Attente de la fin de l'exécution d'un job avec job()
 Possibilité de récupérer pleins de statistiques sur le job

```
# ...
2
    cluster = dispy.JobCluster(compute)
    iobs = []
   for i in range(10):
        job = cluster.submit(random.randint(0, 1000))
6
7
        iob.id = i
        iobs.append(iob)
9
10
   for job in jobs:
11
        n, result = job()
        print('Job #{} : Le carré de {} est {}'.format(job.id, n,
12
        result))
```

Livres de référence



ISBN 978-1-783-28839-7



978-0-321-90563-5

Crédits

- Photos des livres depuis Amazon
- https://www.flickr.com/photos/berkeleylab/4025867073
- https://en.wikipedia.org/wiki/File:IBM_Electronic_Data_Processing_Machine_-_GPN-2000-001881.jpg
- https://www.flickr.com/photos/lovelihood/5399818533
- https://www.flickr.com/photos/toxi/1795660108